GlobalStream

Retenção e segmentação de clientes

Relatório técnico — Introduction to Machine Learning

Identificação	
Instituição:	Faculdade UniFECAF
Disciplina:	Introduction to Machine Learning
Aluno:	Antônio Benevaldo Chaves Santana
Professor:	Raphael Botelho
Curso:	Ciência de Dados

1 Resumo dos resultados

A base fornecida tem 1.000 clientes: 542 com Churn=1 (54,2%) e 458 com Churn=0 (45,8%). A solução, desenvolvida no notebook GlobalStream_Churn.ipynb, realiza auditoria e pré-processamento, segmenta os clientes com K-Means, visualiza os grupos com PCA e compara os quatro classificadores sugeridos no enunciado (Random Forest, Gradient Boosting, SVM e k-NN), com Regressão Logística e um modelo Dummy como referências. Treino (800 clientes) e teste (200 clientes) usam clientes distintos, e o teste só foi consultado depois de fixados o modelo e o limiar.

Tabela 1. Principais resultados.

Resultado	**Evidência calculada**
Qualidade de entrada	Sem ausências, duplicatas ou IDs repetidos. Nenhum outlier no treino pelas regras IQR e $\|z\| > 3$.
Exploração	O churn cresce com os tickets de suporte (correlação de 0,75) e cai com a frequência de acesso (−0,31). Plano e dispositivo não diferem de forma significativa; o gênero favorito tem associação fraca ($p = 0,029$) e quase nenhum poder preditivo.
Segmentação	6 grupos (silhouette de 0,293; estabilidade ARI de 0,72). O churn varia de 5,3% a 100% entre os grupos; os três grupos com muitos tickets reúnem 48% dos clientes e 79,5% dos cancelamentos do treino.
Classificação	O Gradient Boosting teve a maior AUC média na validação cruzada aninhada entre os quatro candidatos (0,977). AUC no teste: 0,982 (IC 95% bootstrap de 0,963 a 0,994).
Limiar de contato	Em 0,17: precisão de 83,7%, recall de 100% e 129 clientes sinalizados entre 200 do teste. Custo ilustrativo 40,6% menor que no limiar padrão de 0,50.

Limitação central: a planilha não possui datas, histórico mensal ou horizonte do alvo. Os resultados avaliam a classificação do Churn registrado. Eles não demonstram, por si só, previsão de cancelamento no próximo mês nem eficácia de uma campanha de retenção.

2 Problema e fundamentos

2.1 Contextualização

O cenário do enunciado descreve a GlobalStream, plataforma de streaming que, após três anos de operação no Brasil, enfrenta aumento do cancelamento de assinaturas. Ofertas genéricas podem consumir orçamento sem responder às causas da saída. A proposta é conhecer perfis de clientes e identificar padrões associados ao churn para orientar ações de marketing e atendimento.

A segmentação organiza clientes por semelhança de comportamento e características contratuais. A classificação estima a associação entre essas características e o rótulo de cancelamento. As duas análises ajudam a formular hipóteses de retenção, mas não medem automaticamente o efeito de uma oferta sobre a decisão do cliente. Os materiais 9, 10 constam entre as referências de estudo indicadas pela disciplina.

Tabela 2. Aprendizado não supervisionado e supervisionado neste trabalho.

Aspecto	**Não supervisionado**	**Supervisionado**
Dados usados	Atributos disponíveis, sem o rótulo Churn.	Atributos e rótulos Churn conhecidos no treino.
Objetivo	Identificar grupos semelhantes.	Aprender uma regra de classificação do alvo.
Métodos	K-Means; PCA para visualização.	Random Forest, Gradient Boosting, SVM e k-NN; Regressão Logística e Dummy como referências.
Avaliação	Silhouette, Davies-Bouldin, estabilidade bootstrap (ARI) e interpretação dos perfis.	ROC AUC (critério de seleção), AP, precisão, recall, F1, acurácia e função ilustrativa de custo.
Decisão apoiada	Hipóteses de comunicação e atendimento por perfil.	Priorização de clientes para políticas que ainda precisam ser validadas.

2.2 Definição operacional adotada

Por convenção do estudo, Churn=1 representa cancelamento e Churn=0 representa permanência. O arquivo não traz um dicionário que detalhe a data ou janela do evento. O ID_Cliente é usado exclusivamente como chave. As sete variáveis explicativas são quatro numéricas e três categóricas; o alvo nunca entra na segmentação nem no pré-processamento dos atributos.

O grupo (cluster) não foi acrescentado como preditor dos classificadores. Agrupamento e classificação são trilhas paralelas, permitindo comparar os modelos com o mesmo conjunto original de características. A unidade amostral é o cliente, e não cliente-mês.

3 Base e auditoria

Fonte: **globalstream_data.xlsx**, aba **Sheet1**, intervalo A1:I1001. O arquivo é usado sem alterações e identificado por SHA-256 em resultados/resultados.json. Não foram gerados registros adicionais, rótulos futuros ou observações mensais. A

origem real ou sintética da planilha não está documentada; o estudo a identifica como base fornecida.

Tabela 3. Colunas da base (1.000 clientes).

Coluna	Conteúdo observado e interpretação
ID_Cliente	1.000 identificadores distintos; não é atributo do modelo.
Meses_Contrato	Inteiros de 1 a 47; média 23,986. Não está definido se representa prazo contratado ou tempo de relacionamento.
Valor_Mensal	30,04 a 59,88; média 45,039. A unidade monetária não está especificada no arquivo.
Frequencia_Acesso_Semanal	0 a 7; média 3,553. Unidade exata de frequência não definida; não equivale a horas assistidas.
Tickets_Suporte	0 a 9; média 4,403. A janela de acumulação não foi informada.
Plano	Basico: 327; Standard: 333; Premium: 340.
Genero_Favorito	Documentarios: 267; Desporto: 251; Filmes: 250; Series: 232.
Dispositivo_Principal	Web: 349; Mobile: 329; Smart TV: 322.
Churn	542 registros com 1 e 458 com 0. Sem data ou horizonte associado.

3.1 Diferenças entre o cenário e a estrutura recebida

O enunciado menciona 24 meses de dados históricos, mas o arquivo fornece apenas um registro por cliente e nenhuma coluna de calendário. Não é possível calcular tendências mensais, construir janelas pré-cancelamento ou executar validação temporal. Também não há tempo de tela: a frequência semanal é o indicador de uso disponível.

Há **220 registros com Meses_Contrato acima de 36** na base (187 no treino, 23,4%). Se a coluna indicar tempo de relacionamento, isso exige esclarecimento diante dos três anos de operação; se indicar prazo do contrato, pode ser compatível. A diferença não foi tratada automaticamente como erro, e os registros foram preservados. A mensalidade média também quase não muda entre planos (Básico 45,11; Standard 44,34; Premium 45,89; Kruskal-Wallis p = 0,103), o que pediria informações sobre descontos e regras comerciais.

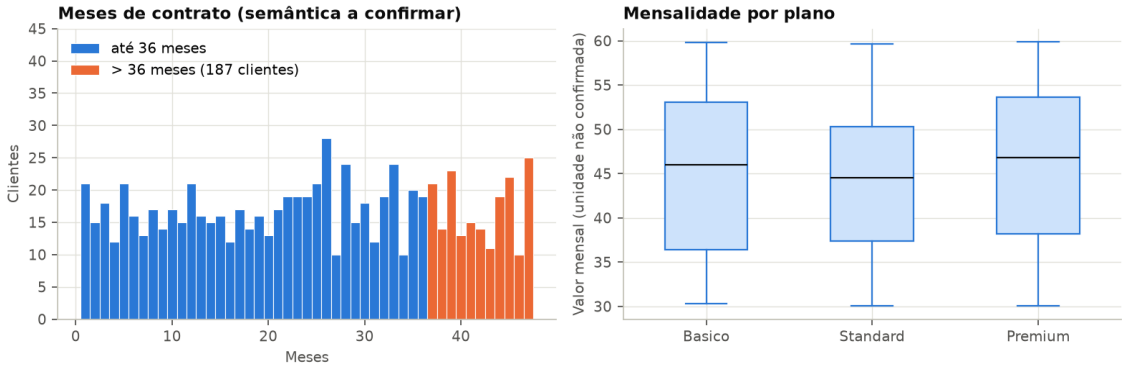


Figura 1. Meses de contrato no treino, com destaque para os valores acima de 36, e mensalidade por plano. Fonte: execução própria.

Ausências, duplicatas exatas, IDs repetidos e violações das regras numéricas declaradas: zero. Os números estão na tabela de auditoria do notebook (seção 1.1).

4 Preparação e exploração

Validação estrutural. O código verifica colunas, identifica IDs vazios ou conflitantes, remove apenas cópias exatas e exige rótulos 0/1 sem ausências. Categorias são padronizadas quanto a espaços e maiúsculas, preservando a grafia original; valores numéricos inválidos, não finitos ou fora do domínio declarado viram ausentes. Na planilha recebida, nenhuma dessas correções foi necessária.

Separação antecipada. Logo após a auditoria, 20% dos clientes (200) foram reservados para teste, com estratificação pelo churn (54,2% no treino e 54,0% no teste). Toda a exploração, a segmentação e a escolha do modelo usam somente os 800 clientes de treino.

Pré-processamento. Mediana para numéricas e moda para categorias são mecanismos preventivos, já que a base não tem ausências. O OneHotEncoder evita impor ordem às categorias e, com handle_unknown='ignore', tolera categorias novas: as três categóricas viram 10 colunas. Imputação, padronização (StandardScaler) e codificação ficam dentro de um Pipeline e são reaprendidas em cada treino, inclusive em cada dobra da validação cruzada, o que evita vazamento 1. Um teste de robustez confirmou que o pipeline pontua sem erro um cliente com valores ausentes e um plano inexistente na base.

Outliers. No treino, calcularam-se os limites Q1 − 1,5×IQR e Q3 + 1,5×IQR e o escore z ($|z| > 3$). Nenhuma variável teve valores fora desses limites (Figura 3), e os dados foram preservados sem winsorização. Um valor extremo estatístico não é automaticamente erro; em outra base, seria preciso avaliar seu significado antes de qualquer tratamento.

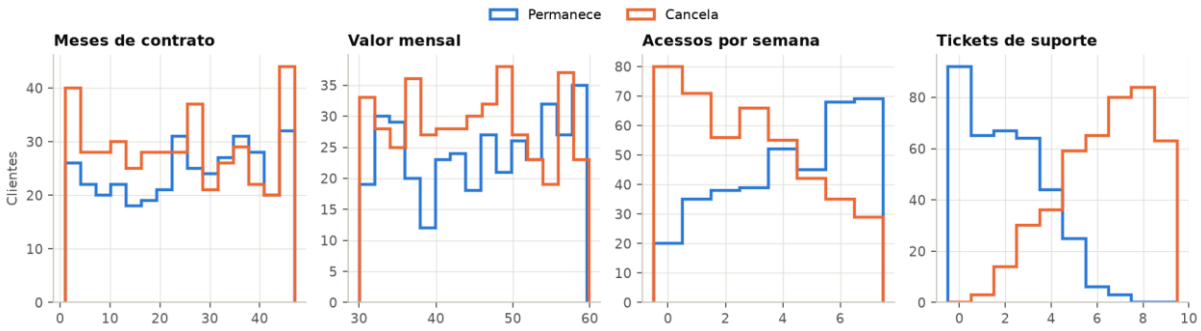


Figura 2. Distribuição das variáveis numéricas por classe no treino. Fonte: execução própria.

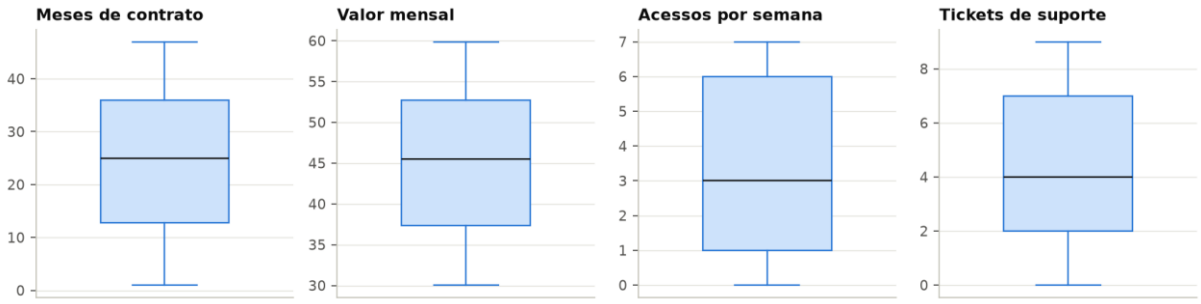


Figura 3. Boxplots das variáveis numéricas do treino; nenhum ponto ultrapassa os limites IQR. Fonte: execução própria.

Churn por variável. No treino, o churn cresce quase continuamente com os tickets de suporte: nenhum cliente sem tickets cancelou, a taxa passa de 70% com 5 tickets e chega a 100% a partir de 8. A frequência de acesso mostra associação no sentido oposto: 80% de churn com frequência 0 e 30% com frequência 7. Tempo de contrato e valor mensal variam pouco em torno da média de 54,2%.

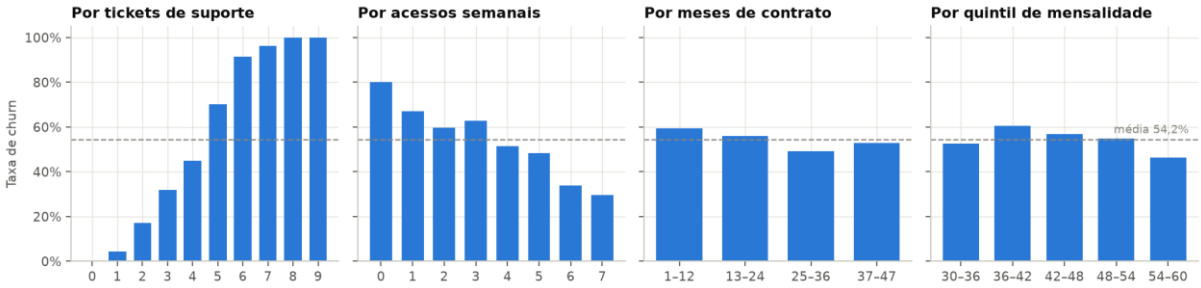


Figura 4. Taxa de churn por nível de cada variável numérica no treino; a linha tracejada é a média. Fonte: execução própria.

Categorias e correlação. Plano (p = 0,19) e dispositivo (p = 0,22) não diferem de forma significativa no churn (teste qui-quadrado). O gênero favorito mostra diferença fraca, significativa a 5% (p = 0,029): 61,8% de churn entre quem prefere Documentários e 48,1% entre quem prefere Séries. Com três testes simultâneos, porém, o resultado não resiste à correção de Bonferroni (0,05/3 ≈ 0,017), e a variável quase não contribui para o classificador (seção 6). Assim, o gênero favorito, citado no enunciado como base das personas, pouco separa quem cancela. As variáveis

numéricas têm correlações lineares baixas entre si; a correlação com o churn é de 0,75 para tickets e −0,31 para frequência, contra −0,06 para meses de contrato e para valor mensal.

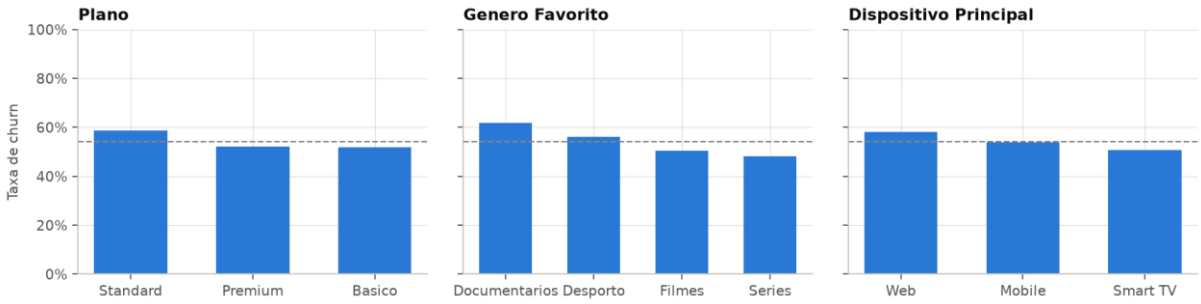


Figura 5. Taxa de churn por categoria no treino; a linha tracejada é a média. Fonte: execução própria.

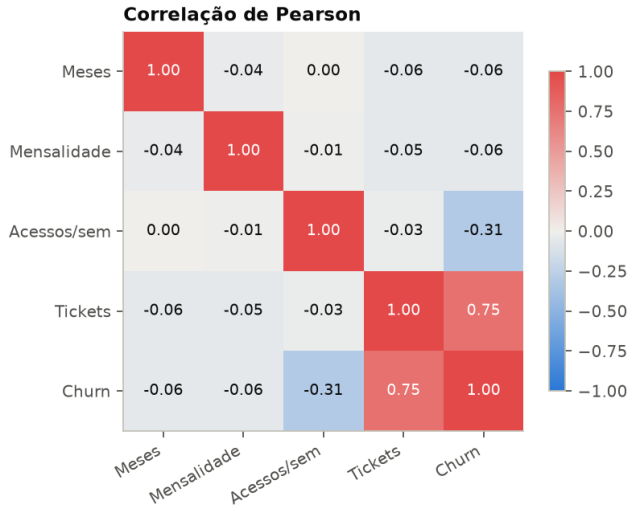


Figura 6. Correlação de Pearson entre as variáveis numéricas e o churn no treino. Fonte: execução própria.

A exploração foi restrita ao treino. Não se criaram ausências ou outliers na base para aparentar limpeza; o comportamento preventivo da imputação foi verificado em cópias usadas apenas nas verificações automáticas do notebook.

5 Segmentação dos clientes

O K-Means agrupa clientes por semelhança após imputação e padronização. Sua escolha favorece simplicidade e descrição por perfis médios, mas pressupõe grupos relativamente compactos 2. Foram comparadas três representações (Tabela 4): as três variáveis comportamentais (frequência de acesso, tickets de suporte e meses de contrato) deram a melhor separação e os perfis mais fáceis de interpretar, e foram adotadas. Plano, gênero e dispositivo ficam fora do agrupamento, mas são usados para descrever os grupos.

Tabela 4. Representações comparadas para a segmentação (treino).

Representação	Dimensões	Melhor silhouette (k = 2 a 8)	k
Comportamento (3 variáveis)	3	0,293	6
Comportamento + mensalidade	4	0,220	8
Comportamento + mensalidade + categóricas	14	0,122	2

Comparar silhouettes entre espaços diferentes é diagnóstico exploratório, não prova de que uma variável seja inútil. Para k de 2 a 8 (50 inicializações cada), calcularam-se inércia, silhouette, Davies-Bouldin e estabilidade por bootstrap (ARI médio em 20 reamostras), apenas no treino. A regra definida foi a maior silhouette: **k = 6** (silhouette de 0,293, Davies-Bouldin de 0,994 e ARI de 0,72). O valor para k = 7 é praticamente igual (0,292); uma silhouette abaixo de 0,3 indica separação moderada a fraca, sem evidência forte de grupos naturais.

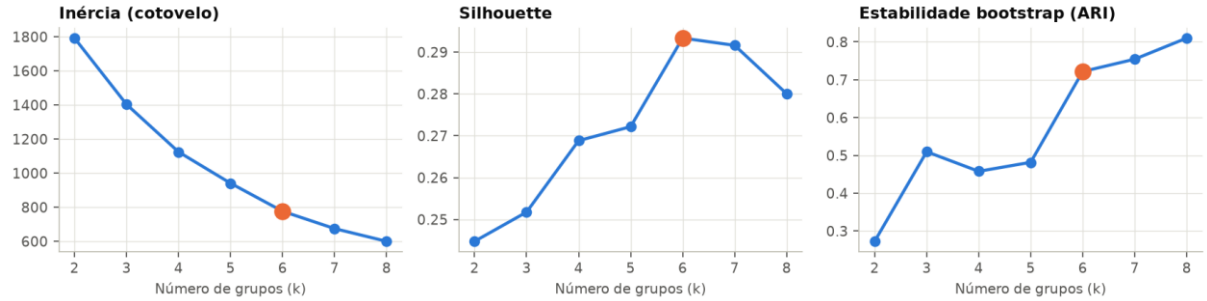


Figura 7. Inércia, silhouette e estabilidade bootstrap por número de grupos; o ponto laranja marca k = 6. Fonte: execução própria.

PCA. As três variáveis padronizadas têm correlações lineares baixas, e cada componente explica cerca de um terço da variância (35,5%, 33,3% e 31,3%). A projeção em duas componentes preserva 68,7% e omite 31,3%. O PCA serve apenas para visualizar; o K-Means opera nas três variáveis padronizadas 3.

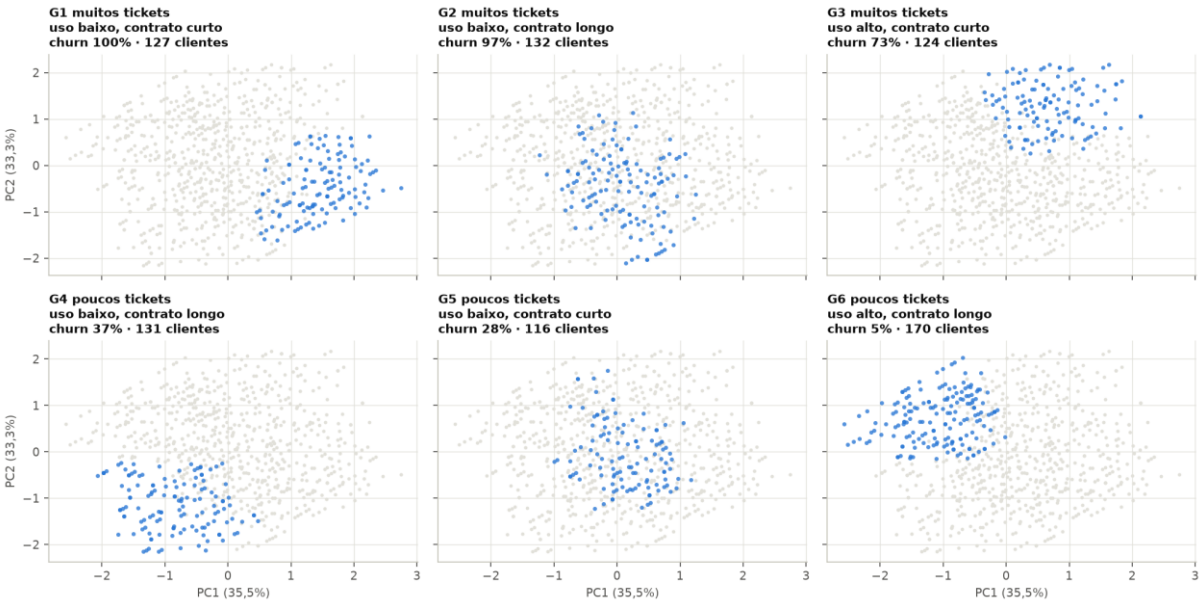


Figura 8. Projeção PCA dos 800 clientes de treino, com cada grupo destacado. Fonte: execução própria.

Os grupos são numerados de G1 (maior churn) a G6 (menor churn) e descritos pela posição do centro de cada grupo em relação à média do treino: tickets (4,37), frequência (3,47) e meses de contrato (24,3). O churn não participou do agrupamento; as taxas foram calculadas depois, para interpretar os grupos.

Tabela 5. Perfis dos grupos no treino (médias) e hipóteses de abordagem.

Grupo	Clientes (treino / teste)	Acessos	Tickets	Meses	Churn	Hipótese de abordagem
G1 muitos tickets, uso baixo, contrato curto	127 / 29	1,3	7,0	14,5	100%	Recuperação pelo suporte antes de qualquer oferta
G2 muitos tickets, uso baixo, contrato longo	132 / 40	3,4	7,2	37,7	97,0%	Recuperação pelo suporte antes de qualquer oferta
G3 muitos tickets, uso alto, contrato curto	124 / 36	5,6	6,2	12,2	72,6%	Suporte técnico prioritário e acompanhamento pós-chamado
G4 poucos tickets, uso baixo, contrato longo	131 / 21	1,7	2,1	36,8	36,6%	Reengajamento por conteúdo
G5 poucos tickets, uso baixo, contrato curto	116 / 32	2,2	1,6	11,4	27,6%	Reengajamento por conteúdo
G6 poucos tickets, uso alto, contrato longo	170 / 42	5,8	2,4	29,3	5,3%	Avaliar benefícios por permanência

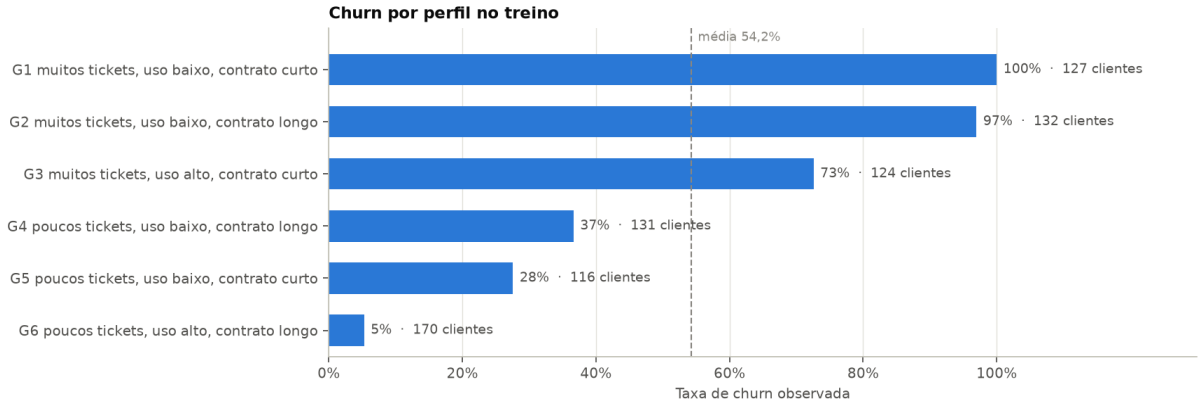


Figura 9. Taxa de churn observada por grupo no treino. Fonte: execução própria.

- **G1 e G2 (muitos tickets, uso baixo; churn de 100% e 97,0%).** Os dois grupos têm uso abaixo da média e muitos tickets, mas diferem nas médias de contrato (14,5 e 37,7 meses) e de frequência (1,3 e 3,4). As taxas observadas não estabelecem efeito causal da duração do contrato. Hipótese: investigar e resolver os chamados antes de oferecer descontos.
- **G3 (muitos tickets, uso alto; 72,6%).** Usa bastante o serviço, mas abre muitos chamados, o que sugere falhas técnicas. Hipótese: suporte prioritário e acompanhamento após o chamado.
- **G4 e G5 (poucos tickets, uso baixo; 36,6% e 27,6%).** Risco intermediário associado ao baixo uso. Hipótese: recomendações pelo gênero favorito e avisos de lançamentos.
- **G6 (poucos tickets, uso alto, contrato longo; 5,3%).** Grupo com menor churn observado. Hipótese: avaliar benefícios por permanência; a eficácia de descontos ou benefícios não foi medida.

G1 a G3 reúnem 48% dos clientes do treino (383 de 800) e 79,5% dos cancelamentos (345 de 434). Não houve evidência estatística suficiente de associação de gênero ($p = 0,35$) ou dispositivo ($p = 0,19$) com os grupos: nenhum gênero passa de 33% dentro de um grupo, e nenhum plano ou dispositivo chega à maioria (máximo de 42,7%). As personas são definidas por suporte, uso e contrato, não por preferência de conteúdo. Não se deve transformar "gênero mais frequente" em preferência do grupo. Distância, escala e escolha de variáveis afetam o resultado; as ações propostas exigem confirmação e experimento controlado.

6 Treinamento e comparação

Divisão estratificada e aleatória por cliente: **800 no treino e 200 no teste**. O desempenho de cada candidato foi estimado por **validação cruzada aninhada** no treino: uma CV externa estratificada de cinco dobras (640 clientes ajustam e 160 avaliam a cada rodada) e, dentro de cada dobra, uma CV interna de cinco dobras

que escolhe os hiperparâmetros por GridSearchCV. Assim, a escolha dos hiperparâmetros nunca usa a dobra que está sendo avaliada 1, 13. A métrica de seleção é a **ROC AUC média** da CV externa. Comparar vários classificadores no mesmo pipeline segue o exemplo de comparação de classificadores do scikit-learn 11.

Tabela 6. Candidatos, justificativa e grades de hiperparâmetros (melhor escolha no treino completo).

Modelo	**Justificativa**	**Grade → escolha**
Dummy	Referência que prevê sempre a classe majoritária (Churn=1); AUC de 0,5.	—
Regressão Logística	Modelo linear regularizado e interpretável; referência de simplicidade.	C ∈ {0,01; 0,1; 1; 10} → C = 0,1
k-NN	Classificação pela vizinhança; muitos vizinhos suavizam a decisão e reduzem a variância.	k ∈ {5; 15; 25; 45}, pesos uniformes ou por distância → k = 45, uniformes
SVM (RBF)	Fronteiras não lineares por kernel RBF; probabilidades estimadas internamente.	C ∈ {0,1; 1; 10}, gamma ∈ {scale; 0,03; 0,1} → C = 1, gamma = 0,03
Random Forest	Interações não lineares com 200 árvores; profundidade e folhas controlam a complexidade.	profundidade ∈ {3; 5; 8; sem limite}, folha mínima ∈ {1; 5; 15} → 5 e 1
Gradient Boosting	Correções sequenciais por árvores rasas, com subamostra de 80%.	árvores ∈ {100; 200}, taxa ∈ {0,05; 0,1}, profundidade ∈ {2; 3} → 100, 0,05 e 2

Os hiperparâmetros finais foram escolhidos no treino completo, antes do teste. O pipeline impede que mediana, moda e escala sejam aprendidas fora do treino. A estratificação mantém proporções semelhantes de classes; 54,2% de positivos não configura desequilíbrio extremo.

Tabela 7. Desempenho na validação cruzada aninhada (treino, 800 clientes).

Modelo	AUC treino	AUC CV ± DP	AP CV	F1 CV	Treino – CV
Dummy	0,500	0,500 ± 0,000	0,542	0,703	0,000
Regressão Logística	0,980	0,977 ± 0,010	0,982	0,915	0,003
k-NN	0,980	0,971 ± 0,009	0,976	0,916	0,009
SVM (RBF)	0,982	0,973 ± 0,011	0,978	0,908	0,010
Random Forest	0,992	0,968 ± 0,012	0,973	0,906	0,023
Gradient Boosting	**0,982**	**0,977 ± 0,010**	**0,981**	**0,919**	**0,005**

Entre os quatro algoritmos sugeridos, o Gradient Boosting teve a maior AUC média (0,977), seguido de SVM (0,973), k-NN (0,971) e Random Forest (0,968). A Regressão Logística teve a mesma AUC após arredondamento a três casas (0,977) e é mais simples; ela foi mantida como referência pela regra definida antes do teste, que restringia a escolha aos quatro algoritmos do enunciado. As diferenças são pequenas frente à variação entre dobras (cerca de ±0,01) e não demonstram superioridade estatística; os desvios são dispersão entre dobras, não intervalos de confiança.

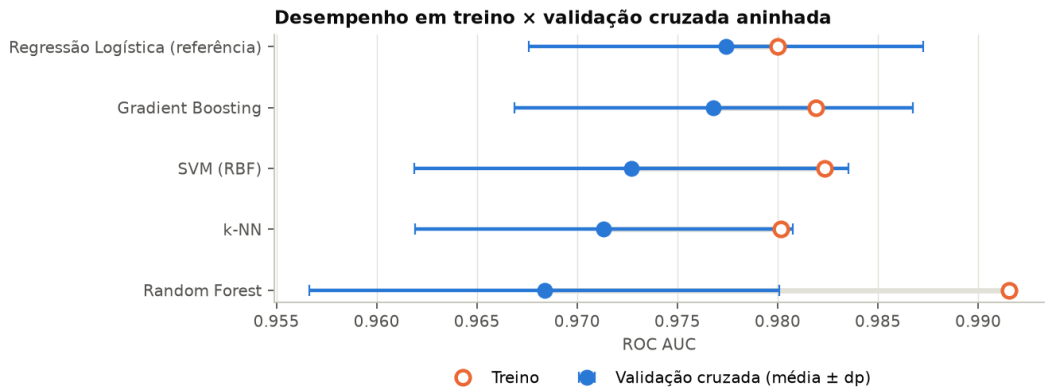


Figura 10. AUC no treino e na validação cruzada aninhada (média ± desvio entre dobras). Fonte: execução própria.

Sobreajuste. A diferença entre a AUC de treino e a da CV é pequena na Regressão Logística (0,003) e no Gradient Boosting (0,005) e maior na Random Forest (0,023), que memoriza mais o treino. A curva de validação (Figura 11) mostra que, com árvores mais profundas, a AUC de treino da Random Forest chega a 1,0, enquanto a da validação para de subir por volta de 0,97 (profundidade 6) e depois cai levemente. Por isso a profundidade foi incluída na grade de busca. A proximidade dos escores, porém, não prova ausência de sobreajuste.

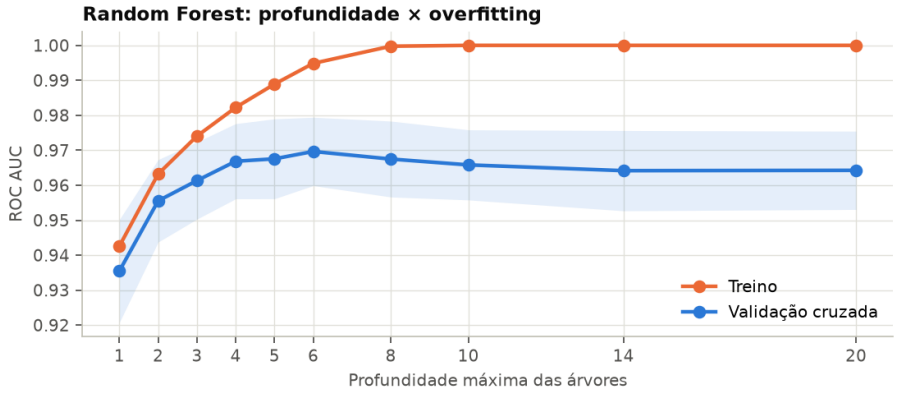


Figura 11. Curva de validação da Random Forest: profundidade máxima das árvores × AUC. Fonte: execução própria.

Importância das variáveis. Por permutação no teste, embaralhar Tickets_Suporte reduz a AUC do modelo em 0,442 e embaralhar a frequência semanal, em 0,047; as demais variáveis têm efeito próximo de zero. Essa importância é preditiva, não causal.

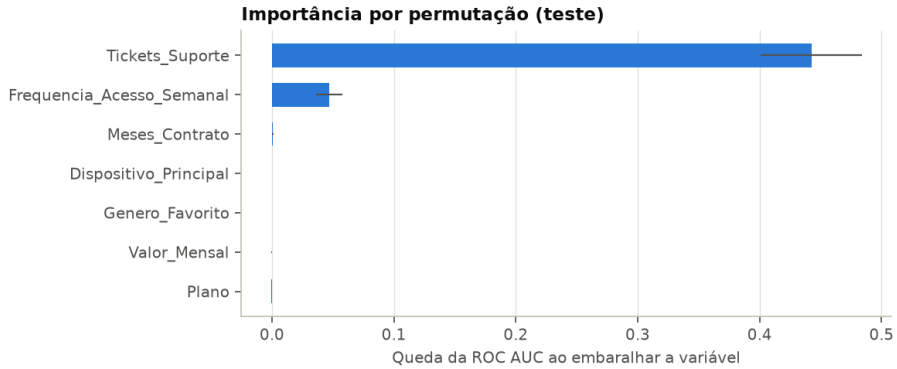


Figura 12. Importância por permutação no teste (queda média da AUC em 30 repetições). Fonte: execução própria.

7 Avaliação do modelo

Precisão = VP/(VP+FP): fração de cancelamentos entre os sinalizados. Recall = VP/(VP+FN): fração dos cancelamentos identificada. F1 combina precisão e recall; acurácia mede todos os acertos. ROC AUC avalia a ordenação em diferentes limiares. Average Precision resume precisão-recall por incrementos de recall e difere da área trapezoidal [4].

O teste (200 clientes, 108 positivos) foi consultado após congelar modelo e limiar. Todos os candidatos aparecem no limiar padrão de 0,50 apenas para comparação diagnóstica.

Tabela 8. Desempenho no teste reservado.

Modelo / limiar	Acurácia	Precisão	Recall	F1	AUC
Dummy / 0,50	54,0%	54,0%	100,0%	0,701	0,500
Reg. Logística / 0,50	93,0%	93,5%	93,5%	0,935	0,984
k-NN / 0,50	92,5%	94,3%	91,7%	0,930	0,981
SVM (RBF) / 0,50	93,0%	93,5%	93,5%	0,935	0,984
Random Forest / 0,50	93,0%	92,7%	94,4%	0,936	0,976
Gradient Boosting / 0,50	94,0%	93,6%	95,4%	0,945	0,982
Gradient Boosting / 0,17	**89,5%**	**83,7%**	**100,0%**	**0,911**	**0,982**

No limiar 0,50, o Gradient Boosting identificou 103 dos 108 cancelamentos, com 7 falsos positivos. No limiar ajustado de 0,17: **108 verdadeiros positivos, 21 falsos positivos, 71 verdadeiros negativos e nenhum falso negativo**; foram sinalizados 129 dos 200 clientes. O recall sobe para 100%, enquanto precisão (de 93,6% para 83,7%), F1 e acurácia (de 94,0% para 89,5%) diminuem. A escolha depende da utilidade e do custo dos erros (seção 8).

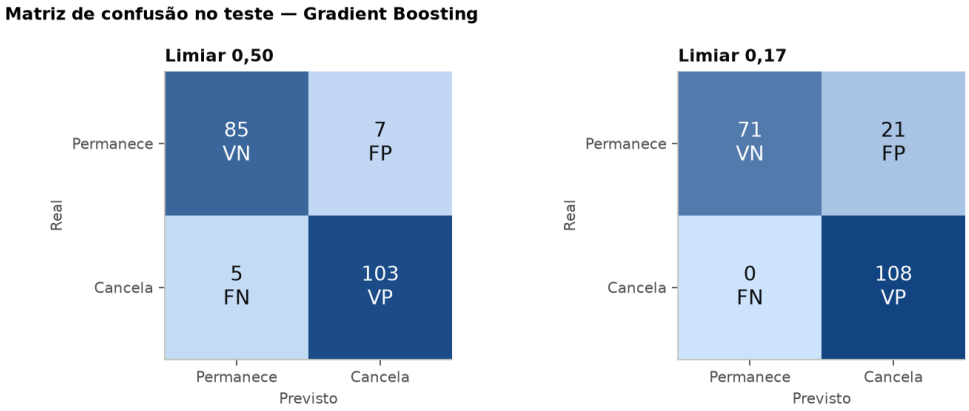


Figura 13. Matrizes de confusão do Gradient Boosting no teste, nos limiares 0,50 e 0,17. Fonte: execução própria.

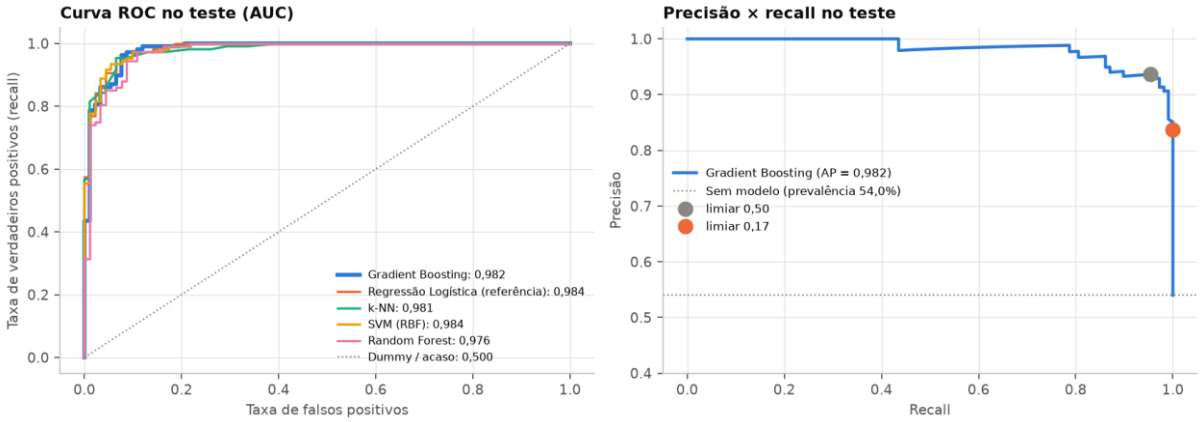


Figura 14. Curvas ROC dos classificadores e curva precisão-recall do Gradient Boosting no teste. Fonte: execução própria.

A AUC de 0,982 tem intervalo percentil bootstrap de 95% de **0,963 a 0,994**, obtido com 1.000 reamostras do teste e o modelo fixo. A AP no teste foi 0,982. No teste, Regressão Logística e SVM tiveram AUC ligeiramente maior (0,984); como o modelo foi escolhido antes, isso não motivou troca. O intervalo não mede instabilidade de retreinamento nem garante validade em outra população ou período.

Os resultados do teste não autorizam afirmar previsão temporal: sem datas, não é verificável se os atributos foram registrados antes do churn. Desempenho alto reforça a necessidade de esclarecer a construção do alvo e os dados disponíveis no momento da decisão.

8 Limiar e utilidade prática

Para explicitar a troca entre os erros, definiu-se uma função ilustrativa de custo: **C = 0,5 × (soma das mensalidades dos falsos positivos) + 3 × (soma das mensalidades dos falsos negativos)**, em unidades monetárias hipotéticas (u.m.). Para clientes de mesma mensalidade, perder um cancelamento custa seis vezes mais que um contato desnecessário. São hipóteses de análise, não custos fornecidos pela GlobalStream nem valores de retorno financeiro.

Foram avaliados limiares de 0 a 1, em passos de 0,01, além de 1,01 (nenhum contato). A escolha usou escores out-of-fold do treino, obtidos com a busca de hiperparâmetros refeita em cada dobra, sem tocar no teste. O menor custo ocorreu em **0,17**: u.m. 2.610,10, contra u.m. 5.651,99 em 0,50. Em caso de empate, prevalece o menor limiar (mais recall). O ajuste da decisão é separado da aprendizagem do escore [5].

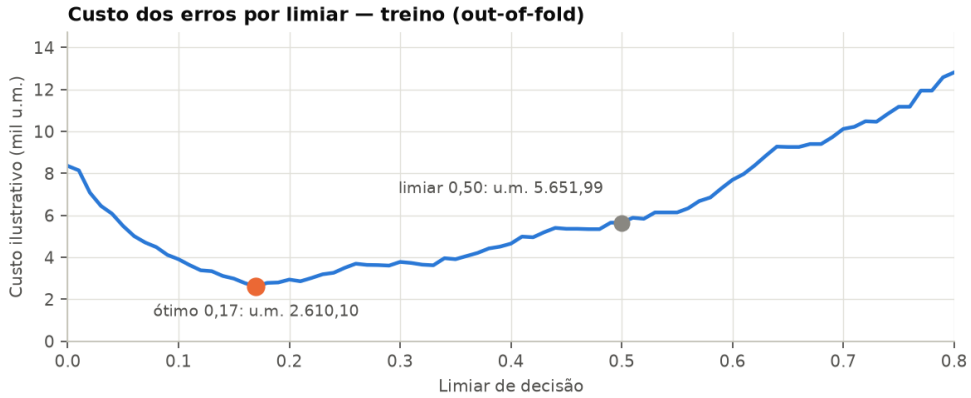


Figura 15. Custo ilustrativo por limiar nos escores out-of-fold do treino. Fonte: execução própria.

Sensibilidade. Com razão de custo FN/FP igual a 1, o limiar ótimo seria 0,52; com razão 2, 0,33; de 4 a 20, permanece em 0,17, com recall out-of-fold de 99,5% e 66,6% da base contatada.

Tabela 9. Políticas de contato avaliadas no teste.

Política no teste	**Contatos**	**FP / FN**	**Custo (u.m.)**
Não contatar ninguém	0	0 / 108	14.345,01
Contatar todos (desconto genérico)	200	92 / 0	2.083,46
Gradient Boosting, t = 0,50	110	7 / 5	811,90
Gradient Boosting, t = 0,17	**129**	**21 / 0**	**482,32**

No teste, o limiar ajustado reduz o custo ilustrativo em **40,6%** frente ao padrão, com 19 contatos adicionais, e em 76,9% frente a contatar todos.

Segmentação × modelo. Com o mesmo número de contatos no teste (105), abordar todos os clientes dos grupos de alto risco (G1 a G3) captaria 92 cancelamentos (precisão de 87,6%, recall de 85,2%, custo de u.m. 2.420,64). Os 105 clientes de maior probabilidade segundo o modelo somam 98 cancelamentos (precisão de 93,3%, recall de 90,7%, custo de u.m. 1.478,17). Nesta comparação do teste, o modelo identificou mais cancelamentos com o mesmo número de contatos. As personas ajudam a formular hipóteses sobre como abordar cada perfil. As duas abordagens são complementares.
A função omite custo de contato nos acertos, valor do cliente, eficácia da oferta e efeitos adversos. Não calcula ROI. Para decidir campanhas, é preciso confirmar custos, calibrar os escores e medir o efeito incremental em um piloto controlado. O cálculo interrompe a execução se houver mensalidade ausente, não finita ou não positiva; a imputação dos atributos do classificador não substitui uma política explícita para custos faltantes.

9 Ética, vieses e produção

9.1 Finalidade e privacidade

Os IDs não são usados como preditores e não há nomes ou contatos no arquivo. Isso não comprova anonimização de uma eventual base real. Em produção, limitar coleta e acessos, proteger dados, definir retenção e documentar a finalidade da análise. Preferências de conteúdo e padrões de uso devem receber atenção por poderem revelar aspectos pessoais. Em uma base real, o tratamento estaria sujeito à Lei Geral de Proteção de Dados (Lei nº 13.709/2018) 12, com destaque para os princípios de finalidade, necessidade e transparência. O titular tem direito de pedir a revisão de decisões tomadas unicamente com base em tratamento automatizado (art. 20); por isso, ofertas personalizadas por modelo devem ter critérios explicáveis e passíveis de revisão humana. A adequação legal deve ser avaliada pelos responsáveis por privacidade da organização.

9.2 Equidade e interpretação

Plano, dispositivo, frequência e solicitações de suporte podem refletir circunstâncias econômicas, acessibilidade ou falhas do próprio serviço. A política não deve penalizar clientes que pedem ajuda nem oferecer condições discriminatórias. No teste, com o limiar 0,17, o recall foi de 100% em todos os planos e dispositivos, e a taxa de falsos positivos variou de 15,6% (Premium) a 27,6% (Standard). Com 63 a 70 clientes por grupo, essas diferenças não são conclusivas. Recomenda-se avaliar diferenças de erros e de tratamento entre grupos pertinentes, com amostras suficientes e governança adequada. Esta base não permite concluir ausência de viés.

Personas são descrições estatísticas provisórias. A separação moderada recomenda evitar rótulos rígidos. A importância do suporte não significa que reduzir a quantidade de tickets cause retenção: pode haver insatisfação, processos de cancelamento registrados como tickets ou outro fator comum. A ordem temporal precisa ser confirmada. Sem Tickets_Suporte, a AUC da validação cruzada cai de 0,977 para 0,681: quase todo o poder preditivo depende dessa variável, o que torna essa confirmação o principal risco de vazamento do projeto. Por outro lado, uma Regressão Logística apenas com tickets e frequência atinge AUC de 0,981 na CV, sinal de que um modelo simples e explicável seria suficiente nesta base.

9.3 Limitações de validade

A origem dos dados, a definição do alvo e as janelas dos atributos não estão documentadas. O teste aleatório mede desempenho entre clientes dessa base sob a hipótese de que os atributos são elegíveis na previsão. Não há teste fora do período, validação em outra população nem comprovação de efeito causal de campanhas. A AUC alta não resolve essas lacunas.

Tabela 10. Próximas etapas.

Próxima etapa	Condição necessária
Contrato de dados	Definir Meses_Contrato, unidade da frequência, moeda, janela dos tickets, horizonte e construção do Churn.
Dados temporais	Obter datas de observação/cancelamento e histórico por cliente. Construir atributos apenas com eventos anteriores ao corte.
Validação externa	Treinar em cortes anteriores e avaliar em cortes posteriores. Reavaliar estabilidade, calibração e diferenças entre grupos.
Piloto controlado	Comparar intervenção e controle, medir retenção incremental, custos completos, reclamações e efeitos adversos.
Monitoramento	Acompanhar qualidade, categorias novas, mudança dos dados, erros, capacidade de atendimento e critérios de retreinamento.

10 Conclusões e reprodução

10.1 Conclusões

A análise atende aos blocos técnicos de preparação, segmentação, classificação e avaliação usando os 1.000 registros fornecidos. O Gradient Boosting obteve a maior AUC na validação cruzada aninhada entre os algoritmos sugeridos, com diferenças pequenas em relação à Regressão Logística e ao SVM. A política sensível ao custo levou o recall a 100% no teste, com redução de precisão. A segmentação, com separação moderada, distingue grupos com churn de 5,3% a 100%: suporte e frequência de uso são os eixos que mais diferenciam os clientes, e os perfis orientam hipóteses, não decisões automáticas definitivas.

A principal melhoria é esclarecer a temporalidade e a construção da base. Em seguida, testar validação temporal, capacidade real de contato, calibração, estabilidade dos agrupamentos e políticas de retenção com avaliação causal. A análise não inventa os 24 meses ausentes nem apresenta a classificação atual como previsão temporal validada.

10.2 Execução e verificações

A execução registrada no pacote foi realizada em Linux com Python 3.12.14 e scikit-learn 1.8.0, com todas as células concluídas sem erros e 16 verificações automáticas aprovadas. As versões utilizadas estão documentadas em resultados/resultados.json.

O notebook executa 16 verificações automáticas. Elas conferem a separação das partições, a exclusão de ID e alvo dos atributos, o ajuste de segmentação e PCA

somente no treino, o tratamento de ausentes e categoria nova, métricas em exemplo conhecido, a soma da matriz de confusão, o mínimo de custo na grade, os perfis de treino, a origem dos escores e os nomes dos grupos. As duas novas verificações conferem o custo em um exemplo conhecido e a rejeição de mensalidade ausente. Todas foram aprovadas na execução entregue. Essas verificações não demonstram eficácia comercial nem ausência de vazamento semântico dos atributos.

Tabela 11. Arquivos da entrega.

Ação	**Arquivo ou orientação**
Relatório teórico	Relatorio_GlobalStream_Revisado.pdf (este relatório).
Parte prática	GlobalStream_Churn.ipynb, com globalstream_data.xlsx e requirements.txt. O envio direto do notebook é aceito pelo enunciado; GitHub é opcional.
Ver resultados	As saídas já estão gravadas no notebook. Ao executá-lo, figuras, tabelas CSV e resultados.json são gravados na pasta resultados/.
Executar	pip install -r requirements.txt e, no Jupyter ou VS Code, Kernel → Restart & Run All. No Google Colab, a célula de carregamento pede o upload da planilha.

Escopo da entrega. Parte Teórica: este relatório, em PDF. Parte Prática: GlobalStream_Churn.ipynb (o enunciado aceita .py ou .ipynb), com a planilha e os resultados. Vídeo pitch: link ao final deste relatório.

11 Referências e rastreabilidade

As referências técnicas abaixo fundamentam os métodos descritos. As referências 9 e 10 integram as fontes sugeridas no enunciado. As orientações sobre pipelines e validação aninhada 1, 13 e o texto legal 12 foram conferidos em 24 de outubro de 2026. Figuras, tabelas e indicadores foram calculados a partir da planilha fornecida.

1 SCIKIT-LEARN. Common pitfalls and recommended practices. Versão 1.8. https://scikit-learn.org/1.8/common_pitfalls.html

2 SCIKIT-LEARN. Clustering. Versão 1.8. https://scikit-learn.org/1.8/modules/clustering.html

3 SCIKIT-LEARN. Decomposing signals in components: PCA. Versão 1.8. https://scikit-learn.org/1.8/modules/decomposition.html

4 SCIKIT-LEARN. Metrics and scoring: quantifying the quality of predictions. Versão 1.8. https://scikit-learn.org/1.8/modules/model_evaluation.html

5 SCIKIT-LEARN. Post-tuning the decision threshold for cost-sensitive learning. Versão 1.8.
https://scikit-learn.org/1.8/auto_examples/model_selection/plot_cost_sensitive_learning.html

6 MICROSOFT. Tutorial: criar, avaliar e pontuar um modelo de previsão de churn. Referência indicada pelo enunciado; não foi utilizada a base desse tutorial.
https://learn.microsoft.com/pt-br/fabric/data-science/customer-churn

7 Enunciado da disciplina. Introduction to Machine Learning: "Otimização de Retenção e Segmentação na GlobalStream", 2026.

8 Base de dados fornecida. globalstream_data.xlsx, aba Sheet1, A1:I1001. Não há documentação sobre geração, calendário ou origem real/sintética no arquivo.

9 SILVA, A. C. da et al. Machine learning com o Google Colab. Revista Semat, Guaratinguetá, v. 5, n. 1, p. 1-10, 2023.
https://revista.gru.ifsp.edu.br/semat/article/download/226/122/1221

10 HOMEM, W. L. Apostila de machine learning. Vitória: PET Engenharia Mecânica UFES, 2023.
https://petmecanica.ufes.br/sites/petengenhariamecanica.ufes.br/files/field/anexo/apostila_do_minicurso_de_machine_learning.pdf

11 SCIKIT-LEARN. Classifier comparison. Documentação oficial.
https://scikit-learn.org/stable/auto_examples/classification/plot_classifier_comparison.html

12 BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).
https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm

13 SCIKIT-LEARN. Nested versus non-nested cross-validation. Versão 1.8.
https://scikit-learn.org/1.8/auto_examples/model_selection/plot_nested_cross_validation_iris.html

11.1 Integridade e revisão

A planilha de entrada é preservada e identificada por SHA-256 em resultados/resultados.json. As partições (particoes.csv), as métricas da CV (comparacao_modelos_cv.csv) e do teste (metricas_teste.csv), os perfis (perfis_personas.csv) e a lista de priorização acompanham o notebook. Este relatório representa a execução entregue; ao alterar base, modelo ou custos, é necessário revisar também o relatório.

Material preparado com assistência de IA para revisão e estudo por Benevaldo. Cabe ao estudante conferir as regras da disciplina, compreender os métodos e revisar a versão final. Não se declara implantação em produção nem validação temporal que não ocorreram.

11.2 Vídeo pitch

Link do vídeo (YouTube, modo não listado): https://youtu.be/PBwlLcjGJQ4